

Représentation des HRTFs par Harmoniques Sphériques

Formalisme mathématique et justification pour l'encodage cross-modal

Mehdi Maqlach

18 juin 2026

Table des matières

1	Introduction	2
2	Harmoniques sphériques	2
2.1	Définition	2
2.2	Propriété fondamentale : orthonormalité	2
2.3	Complétude	3
3	Décomposition d'une HRTF	3
3.1	Problème discret	3
3.2	Solution par moindres carrés	3
3.3	Représentation finale	3
4	Justification pour l'apprentissage cross-modal	4
4.1	Problème d'hétérogénéité résolu proprement	4
4.2	Décorrélacion des caractéristiques	4
4.3	Hiérarchie spatiale interprétable	4
4.4	Reconstruction parfaite et robustesse	4
4.5	Lien avec l'acoustique physique	5
5	Choix de l'ordre L	5
5.1	Compromis précision / compacité	5
5.2	Condition de Nyquist sphérique	5
5.3	Recommandation pratique	5
6	Implémentation	5
7	Conclusion	6

1 Introduction

Une *Head-Related Transfer Function* (HRTF) caractérise la façon dont le son est filtré par la géométrie du corps humain, pavillon de l'oreille, tête, torse, avant d'atteindre le canal auditif. Formellement, pour un sujet donné, la HRTF est une fonction

$$H : S^2 \times \mathbb{R}^+ \longrightarrow \mathbb{C} \quad (\theta, \varphi, f) \longmapsto H(\theta, \varphi, f) \quad (1)$$

où $(\theta, \varphi) \in S^2$ désigne la direction de la source sonore (azimut et élévation sur la sphère unité) et f la fréquence.

Dans les bases de données HRTF mesurées (e.g. HUTUBS, SONICOM), cette fonction est échantillonnée sur un ensemble fini de directions $\{(\theta_i, \varphi_i)\}_{i=1}^N$, dont le cardinal N varie selon le protocole de mesure : $N = 2114, 2818$ ou 8802 dans la base *Database-Master V2-1*. Cette hétérogénéité empêche de représenter directement les HRTFs comme un tableau numpy de forme fixe, ce qui est un prérequis pour tout pipeline d'apprentissage automatique.

Ce document présente la **décomposition en harmoniques sphériques** (SH) comme solution rigoureuse à ce problème : projeter la HRTF sur une base orthonormée de fonctions définies sur S^2 , indépendante de la grille de mesure. La représentation obtenue est de taille fixe, compacte, et physiquement motivée.

2 Harmoniques sphériques

2.1 Définition

Les harmoniques sphériques réelles d'ordre $l \geq 0$ et de degré $|m| \leq l$ sont définies par :

$$Y_l^m(\theta, \varphi) = \begin{cases} \sqrt{2} K_l^m \cos(m\varphi) P_l^m(\cos \theta) & m > 0 \\ K_l^0 P_l^0(\cos \theta) & m = 0 \\ \sqrt{2} K_l^{|m|} \sin(|m|\varphi) P_l^{|m|}(\cos \theta) & m < 0 \end{cases} \quad (2)$$

où P_l^m sont les polynômes de Legendre associés et

$$K_l^m = \sqrt{\frac{(2l+1)(l-|m|)!}{4\pi(l+|m|)!}} \quad (3)$$

est la constante de normalisation. Pour un ordre de troncature L , le nombre total de fonctions de base est

$$N_{\text{SH}}(L) = (L+1)^2 \quad (4)$$

2.2 Propriété fondamentale : orthonormalité

Les harmoniques sphériques forment une base orthonormée de $L^2(S^2)$:

$$\int_{S^2} Y_l^m(\omega) Y_{l'}^{m'}(\omega) d\omega = \delta_{ll'} \delta_{mm'} \quad (5)$$

Cette propriété est l'équivalent sphérique de l'orthogonalité des harmoniques de Fourier sur le cercle. Elle garantit que les coefficients de la décomposition sont *décorrélés* : chaque coefficient capture une composante spatiale indépendante.

2.3 Complétude

Toute fonction de carré intégrable sur S^2 peut être approchée arbitrairement bien par une combinaison finie d'harmoniques sphériques :

$$H(\theta, \varphi, f) = \lim_{L \rightarrow \infty} \sum_{l=0}^L \sum_{m=-l}^l a_l^m(f) Y_l^m(\theta, \varphi) \quad (6)$$

En pratique, les HRTFs sont des fonctions régulières sur S^2 (pas de discontinuité abrupte), ce qui assure une convergence rapide : un ordre L modéré suffit à capturer l'essentiel de l'information spatiale.

3 Décomposition d'une HRTF

3.1 Problème discret

En pratique, on ne dispose que de N mesures aux positions $\{\omega_i\}_{i=1}^N$. Pour une fréquence f et une oreille données, on cherche les coefficients $\mathbf{a}(f) = [a_0^0(f), a_1^{-1}(f), a_1^0(f), \dots, a_L^L(f)]^\top \in \mathbb{R}^{(L+1)^2}$ qui minimisent l'erreur de reconstruction aux positions mesurées.

On définit la **matrice de design** SH :

$$\mathbf{Y} \in \mathbb{R}^{N \times (L+1)^2}, \quad \mathbf{Y}_{i,lm} = Y_l^m(\omega_i) \quad (7)$$

et le vecteur de mesures (log-magnitude en dB) :

$$\mathbf{h}(f) = [\hat{H}(\omega_1, f), \hat{H}(\omega_2, f), \dots, \hat{H}(\omega_N, f)]^\top \in \mathbb{R}^N \quad (8)$$

Le système linéaire à résoudre est :

$$\mathbf{Y} \mathbf{a}(f) = \mathbf{h}(f) \quad (9)$$

3.2 Solution par moindres carrés

Lorsque $N > (L+1)^2$ (système sur-déterminé, ce qui est notre cas), la solution aux moindres carrés est donnée par la pseudo-inverse de Moore-Penrose :

$$\boxed{\hat{\mathbf{a}}(f) = \mathbf{Y}^+ \mathbf{h}(f) = (\mathbf{Y}^\top \mathbf{Y})^{-1} \mathbf{Y}^\top \mathbf{h}(f)} \quad (10)$$

Remarque 1. La matrice $\mathbf{Y}$ ne dépend que des positions de mesure, pas des données HRTF. Elle est donc calculée **une seule fois** par sujet et réutilisée pour toutes les fréquences et les deux oreilles.

3.3 Représentation finale

En appliquant (10) à chaque fréquence f_k ($k = 1, \dots, N_f$) et aux deux oreilles ($e \in \{L, R\}$), on obtient le tenseur de coefficients :

$$\mathbf{A} \in \mathbb{R}^{(L+1)^2 \times N_f \times 2} \quad (11)$$

Ce tenseur constitue la **représentation SH de la HRTF** du sujet. Sa taille est *entièrement déterminée par le choix de L* , indépendamment du nombre N de positions de mesure.

Récapitulatif numérique pour notre base de données (FIR 256 taps, $f_s = 44100$ Hz, donc $N_f = 129$) :

Ordre L	$(L + 1)^2$	Shape $\mathbf{A}$	Taille (float32)	Ratio vs. $N = 2114$
3	16	[16, 129, 2]	16 kB	$\times 0.008$
5	36	[36, 129, 2]	37 kB	$\times 0.017$
10	121	[121, 129, 2]	124 kB	$\times 0.058$
20	441	[441, 129, 2]	453 kB	$\times 0.21$

4 Justification pour l'apprentissage cross-modal

4.1 Problème d'hétérogénéité résolu proprement

La décomposition SH est la **seule approche** qui résout le problème de grilles hétérogènes sans perte d'information et sans artefact :

- **Troncature** au minimum $N_{\min}$: supprime des mesures (perte d'information irréversible, ordre de troncature arbitraire).
- **Moyenne spatiale** : réduction à une dimension, toute information directionnelle détruite.
- **Interpolation** sur grille commune : introduit des artefacts si la densité de la grille source est insuffisante.
- **Décomposition SH** : utilise *toutes* les mesures disponibles (D1 profite de ses 8802 points), produit une représentation de taille fixe, et maximise la précision sous contrainte de compacité.

4.2 Décorrélation des caractéristiques

L'orthogonalité (5) garantit que les coefficients a_l^m sont décorrélés entre eux : chaque coefficient capture une *composante indépendante* de la variation spatiale. Cette propriété est favorable pour un encodeur de type MLP ou CNN, dont l'optimisation est facilitée par des entrées non corrélées.

4.3 Hiérarchie spatiale interprétable

Les harmoniques sphériques de bas ordre capturent les variations **globales** de la HRTF (différence gauche/droite, bas/haut), tandis que les ordres élevés encodent les détails **fins** du pavillon. Cette hiérarchie naturelle est cohérente avec l'objectif du modèle : retrouver la signature spectrale d'une oreille depuis sa photo, qui contient justement ces niveaux de détail emboîtés.

4.4 Reconstruction parfaite et robustesse

Depuis les coefficients $\mathbf{A}$, on peut reconstruire la HRTF à *n'importe quelle direction* (θ, φ) par :

$$\hat{H}(\theta, \varphi, f) = \sum_{l=0}^L \sum_{m=-l}^l a_l^m(f) Y_l^m(\theta, \varphi) \quad (12)$$

Cette propriété est utile en inférence : une fois le modèle entraîné, il prédit $\mathbf{A}$ depuis la photo d'oreille, puis on synthétise la HRTF dans n'importe quelle direction pour la spatialisation binaural.

4.5 Lien avec l'acoustique physique

Les harmoniques sphériques sont les **solutions propres de l'équation de Laplace sur S^2** , et par extension les modes naturels de la propagation acoustique en champ libre. La décomposition SH d'une HRTF est donc *physiquement motivée* : elle sépare les contributions des différentes échelles spatiales de diffraction sur la tête et le pavillon. C'est aussi la base mathématique de l'Ambisonics, standard industriel de l'audio spatial.

5 Choix de l'ordre L

5.1 Compromis précision / compacité

L'erreur de reconstruction décroît quand L augmente. Pour les HRTFs, la littérature [1, 2] montre qu'un ordre $L = 5$ à $L = 10$ capture plus de 95 % de l'énergie spatiale.

5.2 Condition de Nyquist sphérique

Pour que la décomposition soit non-aliasée, il faut que le nombre de mesures N vérifie :

$$N \geq (L + 1)^2 \quad (13)$$

Avec $N_{\min} = 2114$ positions, on peut monter jusqu'à $L \approx 44$ sans sous-détermination.

5.3 Recommandation pratique

Pour une première version du modèle cross-modal :

Contexte	Ordre recommandé
Prototype rapide	$L = 5$ (36 coeff.)
Version de référence	$L = 10$ (121 coeff.)
Haute fidélité	$L = 20$ (441 coeff.)

6 Implémentation

En Python, la décomposition se résume à trois étapes :

1. Lire les positions (θ_i, φ_i) depuis le fichier SOFA.
2. Construire $\mathbf{Y}$ avec `scipy.special.sph_harm`.
3. Résoudre $\mathbf{A} = \mathbf{Y}^+ \mathbf{H}$ avec `numpy.linalg.lstsq`.

La matrice $\mathbf{Y}^+$ est calculée une seule fois par sujet (coût $\mathcal{O}(N \cdot (L+1)^2)$), puis appliquée à toutes les fréquences simultanément par produit matriciel :

$$\mathbf{A} = \mathbf{Y}^+ \mathbf{H} \quad \mathbf{H} \in \mathbb{R}^{N \times N_f \times 2} \longrightarrow \mathbf{A} \in \mathbb{R}^{(L+1)^2 \times N_f \times 2} \quad (14)$$

7 Conclusion

La décomposition en harmoniques sphériques offre une représentation des HRTFs :

- **de taille fixe** : $(L+1)^2 \times N_f \times 2$, indépendante de la grille de mesure ;
- **sans perte** : toutes les mesures contribuent à la solution des moindres carrés ;
- **physiquement motivée** : base propre de la propagation acoustique sphérique ;
- **interprétable** : hiérarchie ordre bas / ordre élevé cohérente avec la géométrie du pavillon ;
- **réversible** : reconstruction à n’importe quelle direction par évaluation de la série tronquée.

Elle constitue donc le prétraitement le plus rigoureux pour alimenter un HRTFEncoder dans une architecture de retrieval cross-modal oreille $\leftrightarrow$ HRTF.

Références

- [1] M. A. Evans, J. A. S. Angus, and A. I. Tew, *Analyzing head-related transfer function measurements using surface spherical harmonics*, J. Acoust. Soc. Am., 104(4) :2400–2411, 1998.
- [2] D. N. Zotkin, R. Duraiswami, and N. A. Gumerov, *Regularized HRTF fitting using spherical harmonics*, in Proc. IEEE WASPAA, 2009.
- [3] B. Rafaely, *Fundamentals of Spherical Array Processing*, Springer, 2015.
- [4] T. Chen, S. Kornblith, M. Norouzi, and G. Hinton, *A simple framework for contrastive learning of visual representations (SimCLR)*, ICML, 2020.