

Personnalisation de HRTF par apprentissage contrastif cross-modal

Appariement photo d'oreille $\leftrightarrow$ représentation en harmoniques sphériques

Mehdi Maqlach

17 août 2026

Résumé

La perception binaurale exacte d'une scène sonore 3D repose sur la *Head-Related Transfer Function* (HRTF) de l'auditeur, qui code la signature spectrale imposée par la géométrie individuelle du pavillon, de la tête et du torse. Les HRTF génériques (moyennées sur une population) dégradent la localisation, en particulier en élévation, tandis que la mesure individuelle en chambre anéchoïque reste inaccessible en dehors du laboratoire. Ce document présente un modèle de **récupération cross-modale** : un espace latent partagé est appris entre deux modalités — une paire de photographies d'oreilles et une HRTF mesurée — de sorte qu'à l'inférence, la HRTF la plus proche d'un nouvel utilisateur puisse être retrouvée par similarité cosinus depuis ses seules photos. Nous justifions le choix d'une représentation en harmoniques sphériques pour la HRTF, une architecture siamoise pour l'encodeur d'image, une perte contrastive de type NT-Xent en variante supervisée, et une augmentation de données fondée sur une symétrie exacte du problème plutôt que sur une interpolation brute. Le protocole d'évaluation (Recall@ k , MRR, distorsion log-spectrale) et une méthode d'interprétabilité par Grad-CAM adaptée à l'architecture sont également détaillés.

Table des matières

1	Introduction	2
1.1	Motivation	2
1.2	Approche retenue	3
1.3	Contributions	3
2	Travaux connexes	3
3	Données et représentation	4
3.1	Deux bases de données, deux rôles	4
3.2	Décomposition en harmoniques sphériques	4
3.3	Prétraitement des images	5
4	Formulation du problème	5

5	Architecture du modèle	5
5.1	EarEncoder — réseau siamois	5
5.2	HRTFEncoder	6
6	Fonction de perte	6
6.1	NT-Xent standard	6
6.2	Supervised NT-Xent — nécessaire en présence d’augmentation	6
6.3	Température τ	7
7	Augmentation par symétrie azimutale	7
7.1	Motivation	7
7.2	Dérivation	7
7.3	Application offline et online, anti-fuite	8
8	Entraînement	8
8.1	Dégel progressif en trois phases	8
8.2	Callbacks et infrastructure	8
8.3	Extension : apprentissage fédéré	9
9	Inférence	9
9.1	Gallery	9
9.2	HRTFPredictor	9
10	Évaluation	9
10.1	Métriques de retrieval	9
10.2	Distorsion log-spectrale (LSD)	9
10.3	Séparabilité de l’espace latent	10
10.4	Protocole anti-fuite	10
11	Interprétabilité	10
12	Discussion et limites	10
13	Conclusion et perspectives	11

1 Introduction

1.1 Motivation

Une HRTF $H(\varphi, \theta, f)$ décrit le filtrage acoustique subi par une onde sonore provenant de la direction (φ, θ) avant d’atteindre le tympan. Ce filtrage dépend fortement de la morphologie individuelle du pavillon — ses replis (hélix, anthélix, conque) créent des résonances et des annulations spécifiques à chaque sujet, en particulier au-dessus de 6 kHz, qui sont les indices dominants de la perception de l’élévation et de la résolution avant/arrière.

Deux stratégies existent pour spatialiser un signal en binaural :

- convoluer avec une HRTF **générique** (moyenne de population) — robuste mais acoustiquement fausse pour tout individu s’écartant de la moyenne, source de confusions avant/arrière et d’une élévation perçue aplatie ;

- convoluer avec la HRTF **individuelle**, mesurée en chambre anéchoïque — fidèle mais nécessitant un protocole de mesure lourd (réseau de haut-parleurs, immobilisation du sujet), inapplicable à grande échelle.

1.2 Approche retenue

Nous formulons la personnalisation non pas comme un problème de *régression* (prédire directement les échantillons temporels d’une HRTF depuis une image, tâche mal posée avec un nombre de sujets mesurés nécessairement restreint), mais comme un problème de **retrieval cross-modal** : apprendre une fonction d’encodage pour chaque modalité telle que les deux représentations d’un même sujet soient proches dans un espace latent commun, puis retrouver par plus-proche-voisin la HRTF mesurée la plus vraisemblable pour un nouvel utilisateur.

Cette formulation, popularisée en vision-langage par CLIP [8], présente un avantage décisif pour notre contexte : la sortie du modèle est toujours une HRTF *physiquement valide* (une mesure réelle de la base de référence), ce qui élimine le risque de synthétiser un filtre non causal ou acoustiquement aberrant — risque inhérent à toute régression directe entraînée sur peu d’exemples.

1.3 Contributions

1. Une représentation de la HRTF en **harmoniques sphériques** (SH), de taille fixe et indépendante de la grille de mesure du sujet (détail complet dans le document compagnon [1]), utilisée ici comme entrée de l’encodeur HRTF.
2. Une architecture à deux encodeurs (**EarEncoder**, **HRTFEncoder**) projetant chaque modalité dans un espace latent L_2 -normalisé partagé.
3. Une perte contrastive **NT-Xent supervisée**, choisie pour traiter correctement les échantillons augmentés d’un même sujet comme des positifs multiples plutôt que comme des faux négatifs.
4. Une augmentation de données par **réflexion azimutale exacte**, dérivée analytiquement de la parité des harmoniques sphériques réelles — et non d’une interpolation ou d’un bruit ajouté.
5. Un protocole d’entraînement en trois phases (*progressive unfreezing*) et un protocole d’évaluation anti-fuite adapté à un nombre de sujets restreint.

2 Travaux connexes

Personnalisation de HRTF. Les approches historiques reposent sur des mesures anthropométriques (largeur de tête, taille du pavillon) reliées à la HRTF par régression ou par sélection dans une base (*best-matched HRTF*). Notre approche s’en distingue en utilisant directement l’image plutôt que des mesures manuelles, et en formulant le problème comme un retrieval plutôt qu’une régression paramétrique.

Apprentissage contrastif. SimCLR [4] et la perte InfoNCE [5] (elle-même héritière de la N-pair loss [6]) établissent le cadre général : rapprocher les représentations de paires positives et éloigner celles de paires négatives via une cross-entropie softmax température-contrôlée. CLIP [8] étend ce cadre au cas **cross-modal** (image $\leftrightarrow$ texte) — c’est le cadre que nous transposons ici à (image d’oreille $\leftrightarrow$ HRTF). La *Supervised Contrastive Loss* [7]

généralise encore ce cadre en autorisant plusieurs positifs par ancre, ce qui est notre cas en présence d’augmentation par sujet.

Interprétabilité. Grad-CAM [10] est repris ici dans une variante adaptée à une tête d’embedding contrastive L_2 -normalisée (section 11), un cas non standard où le score de classe usuel n’existe pas.

3 Données et représentation

3.1 Deux bases de données, deux rôles

Le projet s’appuie sur deux corpus HRTF distincts, à des fins différentes :

Base	Rôle	Contenu
IRCAM LISTEN	moteur DSP (interpolation, synthèse)	6 sujets, grille de 187 positions
Base cross-modale ¹	entraînement du modèle contrastif	sujets avec HRIR + photos d’oreilles G

Le modèle décrit dans ce document est entraîné exclusivement sur la seconde base. Une exécution observée dans le pipeline d’entraînement donne, après expansion par augmentation (section 7), un total de 80 sujets répartis en 57 (train) / 11 (val) / 12 (test), avec un ordre SH $L = 10$ (soit 121 coefficients par oreille).

3.2 Décomposition en harmoniques sphériques

Les positions de mesure varient d’un sujet à l’autre et d’une base à l’autre (de 187 à plusieurs milliers de points), ce qui interdit de représenter la HRTF comme un tenseur de forme fixe sans prétraitement. La solution retenue projette la HRTF sur la base orthonormée des harmoniques sphériques réelles Y_l^m :

$$H(\varphi, \theta, f) \approx \sum_{l=0}^L \sum_{m=-l}^l a_l^m(f) Y_l^m(\varphi, \theta), \quad Y_l^m(\varphi, \theta) = \begin{cases} \sqrt{2} K_l^m \cos(m\varphi) P_l^m(\cos \theta) & m > 0 \\ K_l^0 P_l^0(\cos \theta) & m = 0 \\ \sqrt{2} K_l^{|m|} \sin(|m|\varphi) P_l^{|m|}(\cos \theta) & m < 0 \end{cases} \quad (1)$$

avec $K_l^m = \sqrt{\frac{2l+1}{4\pi} \frac{(l-|m|)!}{(l+|m|)!}}$. Pour un ordre de troncature L , le nombre de coefficients est fixe et vaut $n_{sh} = (L+1)^2 - 121$ pour $L = 10$ — indépendamment du nombre de positions mesurées.

Les coefficients sont obtenus par moindres carrés : en notant $\mathbf{Y} \in \mathbb{R}^{N \times n_{sh}}$ la matrice de design ($\mathbf{Y}_{i,lm} = Y_l^m(\varphi_i, \theta_i)$) et $\mathbf{h}(f) \in \mathbb{R}^N$ le vecteur de log-magnitudes mesurées à la fréquence f ,

$$\hat{\mathbf{a}}(f) = \mathbf{Y}^+ \mathbf{h}(f) = (\mathbf{Y}^\top \mathbf{Y})^{-1} \mathbf{Y}^\top \mathbf{h}(f). \quad (2)$$

Appliqué à chaque bin fréquentiel et aux deux oreilles, ceci produit le tenseur $\mathbf{A} \in \mathbb{R}^{n_{sh} \times N_f \times 2}$ qui constitue l’entrée de l’encodeur HRTF ($N_f = 129$ pour un FIR de 256

1. Structure compatible HUTUBS [12] / SONICOM : un dossier par sujet contenant un fichier *_SOFA.sofa et des scans/photos d’oreille gauche et droite.

échantillons à 44,1 kHz). Cette représentation est justifiée en détail — orthogonalité, complétude, hiérarchie spatiale interprétable, lien avec les modes propres de l’équation de Laplace sur S^2 — dans le document compagnon *Représentation des HRTFs par Harmoniques Sphériques* [1]; nous n’en reprenons ici que les éléments strictement nécessaires à l’architecture du modèle.

3.3 Prétraitement des images

Chaque photo d’oreille est redimensionnée en $224 \times 224 \times 3$ (interpolation Lanczos) et normalisée dans $[0, 1]$. Aucune normalisation supplémentaire n’est appliquée en amont du réseau : le *rescaling* vers l’échelle attendue par EfficientNet ($[0, 255]$) est intégré comme première couche du modèle (section 5.1), afin que la même fonction de prétraitement s’applique identiquement à l’entraînement et à l’inférence.

Les coefficients SH sont normalisés en z -score, $\tilde{a} = (a - \mu_{\text{train}})/\sigma_{\text{train}}$, avec $\mu_{\text{train}}, \sigma_{\text{train}}$ estimés uniquement sur le split d’entraînement — condition nécessaire pour ne pas laisser fuiter d’information des sujets de validation/test dans la normalisation.

4 Formulation du problème

Définition 1 (Espace latent partagé). *Soit I_L, I_R les photos d’oreille gauche/droite d’un sujet et $\mathbf{A}$ ses coefficients SH. On cherche deux fonctions*

$$f_{\text{ear}} : (I_L, I_R) \mapsto z_{\text{ear}} \in \mathbb{S}^{d-1}, \quad f_{\text{hrtf}} : \mathbf{A} \mapsto z_{\text{hrtf}} \in \mathbb{S}^{d-1},$$

paramétrées par des réseaux de neurones et projetant sur la sphère unité de $\mathbb{R}^d$ ($d = 128$), telles que pour un même sujet i , $z_{\text{ear},i}$ et $z_{\text{hrtf},i}$ soient les plus proches possibles au sens du cosinus, et éloignés de ceux de tout autre sujet.

La contrainte $z \in \mathbb{S}^{d-1}$ (L_2 -normalisation en sortie des deux encodeurs) n’est pas cosmétique : elle rend le produit scalaire équivalent à la similarité cosinus, $\langle z_{\text{ear}}, z_{\text{hrtf}} \rangle = \cos(z_{\text{ear}}, z_{\text{hrtf}})$, condition requise par la perte NT-Xent (section 6) et par la recherche du plus proche voisin en inférence (section 9).

5 Architecture du modèle

5.1 EarEncoder — réseau siamois

$$\begin{aligned} I_L, I_R &\in [0, 1]^{224 \times 224 \times 3} \\ F_L &= \text{EffNetB0}(255 \cdot I_L), \quad F_R = \text{EffNetB0}(255 \cdot I_R) \quad (\text{poids } \mathbf{partagés}) \\ x &= \text{Concat}[\text{GAP}(F_L), \text{GAP}(F_R)] \in \mathbb{R}^{2560} \\ x &\rightarrow \text{Dense}(512, \text{relu}) \rightarrow \text{Dropout}(0.3) \rightarrow \text{Dense}(256, \text{relu}) \rightarrow \text{Dense}(128) \\ z_{\text{ear}} &= x/\|x\|_2 \in \mathbb{S}^{127} \end{aligned} \tag{3}$$

Le partage des poids entre les deux branches gauche/droite (*Siamese network*) n’est pas un simple gain de paramètres : il encode a priori que la fonction *morphologie du*

pavillon $\rightarrow$ *signature spectrale* est la même quelle que soit l’oreille, et réduit d’un facteur deux la variance d’estimation pour un nombre de sujets mesurés restreint.

Le *backbone* EfficientNet-B0 [9] est pré-entraîné sur ImageNet. Le *fine-tuning* se fait en trois phases de dégel progressif (section 8), une stratégie standard en apprentissage par transfert avec peu de données : entraîner d’abord la tête seule évite que des gradients de large amplitude, issus d’une tête initialisée aléatoirement, ne détruisent les features génériques du backbone pré-entraîné.

5.2 HRTFEncoder

$$\begin{aligned} \mathbf{A} \in \mathbb{R}^{n_{sh} \times N_f \times 2} &\xrightarrow{\text{reshape}} \mathbb{R}^{n_{sh} \times (2N_f)} \\ &\xrightarrow{\text{Dense(32,relu) partagé sur } n_{sh}} \mathbb{R}^{n_{sh} \times 32} \xrightarrow{\text{flatten}} \mathbb{R}^{32 n_{sh}} \\ &\rightarrow \text{Dense(256, relu)} \rightarrow \text{Dropout(0.3)} \rightarrow \text{Dense(128)} \rightarrow z_{\text{hrtf}} = x / \|x\|_2 \in \mathbb{S}^{127} \end{aligned} \quad (4)$$

La couche Dense(32) est appliquée identiquement à chacune des n_{sh} lignes de coefficients avant l’aplatissement — elle joue le rôle d’un encodeur *par harmonique*, cohérent avec le fait que chaque ligne $a_l^m(\cdot)$ est une composante spatiale décorrélée des autres (propriété d’orthogonalité, éq. (1)).

6 Fonction de perte

6.1 NT-Xent standard

Pour un batch de N paires $(z_{\text{ear},i}, z_{\text{hrtf},i})_{i=1}^N$, on définit la similarité température-contrôlée $s_{ij} = \langle z_{\text{ear},i}, z_{\text{hrtf},j} \rangle / \tau$. Le problème de retrouver la HRTF du sujet i parmi les N candidats du batch est traité comme une classification à N classes :

$$\mathcal{L}_{\text{ear} \rightarrow \text{hrtf}} = -\frac{1}{N} \sum_{i=1}^N \log \frac{\exp(s_{ii})}{\sum_{k=1}^N \exp(s_{ik})}, \quad \mathcal{L}_{\text{hrtf} \rightarrow \text{ear}} = -\frac{1}{N} \sum_{i=1}^N \log \frac{\exp(s_{ii})}{\sum_{k=1}^N \exp(s_{ki})} \quad (5)$$

$$\boxed{\mathcal{L}_{\text{NT-Xent}} = \frac{1}{2} (\mathcal{L}_{\text{ear} \rightarrow \text{hrtf}} + \mathcal{L}_{\text{hrtf} \rightarrow \text{ear}})} \quad (6)$$

La symétrisation force l’espace latent à être cohérent dans les deux sens de récupération (oreille $\rightarrow$ HRTF et HRTF $\rightarrow$ oreille), plutôt que de sur-optimiser un seul sens au détriment de l’autre.

6.2 Supervised NT-Xent — nécessaire en présence d’augmentation

L’augmentation par réflexion azimutale (section 7) crée, pour un sujet de base b , plusieurs échantillons $(b, b_{\text{mirror}}, \dots)$ dans le même batch. Sous NT-Xent standard, deux échantillons du même sujet de base occupant des lignes différentes de la matrice s seraient traités comme des **négatifs** l’un de l’autre — un faux négatif structurel qui pousse le modèle à *séparer* des représentations qui devraient au contraire être proches.

Soit $P(i) = \{j : \text{label}(j) = \text{label}(i)\}$ l'ensemble des indices du batch partageant le même sujet de base que i (labels attribués via l'identifiant avant suffixe, *ex.* `H10_mirror` $\rightarrow$ `H10`). La perte supervisée [7], adaptée au cadre cross-modal, moyenne la log-vraisemblance sur tous les positifs de l'ancre :

$$\mathcal{L}_i^{\text{ear} \rightarrow \text{hrtf}} = -\frac{1}{|P(i)|} \sum_{p \in P(i)} \log \frac{\exp(s_{ip})}{\sum_{k=1}^N \exp(s_{ik})} \quad (7)$$

et symétriquement pour $\mathcal{L}_i^{\text{hrtf} \rightarrow \text{ear}}$; la perte totale est la moyenne batch des deux termes sur $i = 1, \dots, N$. C'est ce mode (`supervised=True`) qui est utilisé par défaut dès lors que le dataset est augmenté.

6.3 Température τ

$\tau = 0,07$ (valeur reprise de SimCLR [4]) contrôle la netteté de la distribution softmax sur les similarités : un τ faible pénalise fortement les négatifs proches du positif (utile quand N est petit, comme ici, pour extraire un signal d'apprentissage suffisant d'un nombre limité de négatifs par batch), tandis qu'un τ élevé lisse la distribution et ralentit la convergence.

7 Augmentation par symétrie azimutale

7.1 Motivation

Avec seulement quelques dizaines de sujets mesurés, l'augmentation de données est indispensable. Une interpolation ou un *mixup* naïf entre deux HRTF de sujets différents introduit des artefacts de phase (deux HRIR aux délais d'onset différents s'annulent partiellement en moyenne complexe directe) sans justification acoustique. On lui préfère ici une transformation qui est une **symétrie exacte** du problème : la réflexion gauche/droite d'une tête (approximativement) bilatéralement symétrique.

7.2 Dérivation

Proposition 1 (Symétrie azimutale des coefficients SH réels). *Soit un sujet de HRTF gauche $H_L(\varphi, \theta, f)$ et droite $H_R(\varphi, \theta, f)$. Sous l'hypothèse de symétrie bilatérale de la tête, le sujet miroir obtenu en réfléchissant l'azimut ($\varphi \rightarrow -\varphi$) satisfait $H_L^{\text{mirror}}(\varphi, \theta, f) = H_R(-\varphi, \theta, f)$ et réciproquement. En notant a_l^m les coefficients SH du sujet original, les coefficients du sujet miroir vérifient*

$$a_l^{m, \text{mirror}} = \sigma(m) \cdot a_l^m, \quad \sigma(m) = \begin{cases} -1 & m < 0 \\ +1 & m \geq 0 \end{cases} \quad (8)$$

avec échange simultané des canaux gauche/droite.

Démonstration. Dans l'éq. (1), la dépendance en φ n'apparaît que via $\cos(m\varphi)$ (termes $m > 0$) et $\sin(|m|\varphi)$ (termes $m < 0$) ; le facteur de Legendre $P_l^{|m|}(\cos \theta)$ est invariant par $\varphi \rightarrow -\varphi$. Or $\cos(-m\varphi) = \cos(m\varphi)$ (fonction paire) tandis que $\sin(-|m|\varphi) = -\sin(|m|\varphi)$ (fonction impaire). Comme la projection SH (éq. (2)) est linéaire en les valeurs de H , la réflexion des positions se traduit exactement par le changement de signe (8) appliqué aux coefficients, sans qu'aucune ré-estimation par moindres carrés ne soit nécessaire. $\square$

Remarque 1. Cette transformation est *exacte et sans perte*, contrairement à une augmentation stochastique (bruit gaussien, mixup linéaire) : elle ne fait qu’exploiter une symétrie déjà présente dans la base Y_L^m . C’est pour cette même raison que l’interpolation phase/onset — et non une interpolation complexe directe — est utilisée ailleurs dans le projet (module d’interpolation spatiale de la HRTF) : dans les deux cas, on évite d’introduire un artefact de phase en respectant la structure du problème plutôt qu’en interpolant des représentations où cette structure n’est pas linéaire.

En parallèle, les images sont transformées par échange gauche/droite suivi d’un miroir horizontal : $I_L^{\text{mirror}} = \text{flip}(I_R)$, $I_R^{\text{mirror}} = \text{flip}(I_L)$ — cohérent géométriquement avec la réflexion appliquée aux coefficients SH.

7.3 Application offline et online, anti-fuite

L’expansion $N \rightarrow 2N$ sujets (`expand()`) est appliquée **avant** le split train/val/test, afin que chaque sujet miroir soit disponible pour la même expansion en aval. Une seconde couche d’augmentation, appliquée *online* par `tf.data.map()` **uniquement sur le train set**, permet de tirer une réflexion aléatoire (probabilité $p = 0,5$) à chaque epoch — le val/test set restent non augmentés pour donner une mesure honnête de la performance.

Le fait que l’expansion précède le split introduit malgré tout une fuite partielle : un sujet peut se retrouver en version originale dans le train set et en version miroir dans le val set. Le protocole d’évaluation (section 10) neutralise cette fuite en comparant les identifiants de *sujet de base* plutôt que les identifiants exacts.

8 Entraînement

8.1 Dégel progressif en trois phases

Phase	Backbone EfficientNet-B0	Paramètres entraînaibles	Taux d’apprentissage
1	entièrement gelé	$\sim 1,4$ M (tête seule)	10^{-3}
2	20 dernières couches dégelées	~ 5 M	10^{-4}
3	entièrement dégelé	$\sim 6,5$ M	10^{-5}

Cette décroissance du taux d’apprentissage de deux ordres de grandeur au fil des phases est le pendant nécessaire de l’ouverture progressive du nombre de paramètres entraînaibles : un $\text{lr} = 10^{-3}$ appliqué au backbone entier (phase 3) détruirait les poids pré-entraînés avant que la tête n’ait eu le temps de fournir un signal de gradient informatif.

8.2 Callbacks et infrastructure

Chaque phase est équipée de `EarlyStopping` (patience 10, restauration des meilleurs poids), `ReduceLR0nPlateau` (facteur 0,5, patience 5) et `ModelCheckpoint`. Un `RecallCallback` recalcule, à chaque epoch, une gallery d’embeddings HRTF depuis le train set et mesure le Recall@1 des photos du val set (section 10) — une métrique de bout en bout, plus directement interprétable que la seule valeur de la perte. L’ensemble est tracé et versionné via TensorBoard et MLflow (hash du dataset, hyperparamètres, courbes, artefacts de poids par phase), pour garantir la reproductibilité des expériences.

8.3 Extension : apprentissage fédéré

Les photos d'oreilles sont une donnée biométrique sensible. Une extension du **Trainer** vers un cadre fédéré (**FedAvg** [11], via le framework Flower) permet à plusieurs clients d'entraîner localement le **ContrastiveModel** sur leurs propres sujets sans jamais centraliser les images : seuls les poids du modèle (ou leurs mises à jour, potentiellement chiffrées de façon homomorphe pour l'agrégation) transitent vers le serveur. Cette direction, explorée dans le projet à titre de preuve de concept, est discutée plus en détail en perspective (section 12).

9 Inférence

9.1 Gallery

La **Gallery** est une base de référence construite **une seule fois** depuis le train set : pour chaque sujet connu, elle stocke l'embedding z_{hrtf} (L_2 -normalisé) et les coefficients SH dénormalisés associés. La recherche du plus proche voisin est un simple produit scalaire,

$$\text{score}(i) = \langle z_{\text{hrtf},i}, z_{\text{ear}} \rangle, \quad \hat{i} = \arg \max_i \text{score}(i), \quad (9)$$

les deux membres étant sur $\mathbb{S}^{127}$, ce score est directement un cosinus $\in [-1, 1]$.

9.2 HRTFPredictor

Depuis deux photos d'un nouvel utilisateur, le pipeline complet retourne le sujet le plus proche, son score de similarité, et ses coefficients SH — que l'on peut ensuite **décoder à n'importe quelle direction** via $\hat{H}(\varphi, \theta, f) = \sum_{l,m} a_l^m(f) Y_l^m(\varphi, \theta)$ (éq. (1)), pour alimenter le moteur de convolution binaurale du projet (**HRTFInterpolator**, **DynamicConvolver**).

10 Évaluation

10.1 Métriques de retrieval

Pour un ensemble de N sujets test avec matrice de similarité $s_{ij} = \langle z_{\text{ear},i}, z_{\text{hrtf},j} \rangle$:

$$\text{Recall}@k = \frac{1}{N} \sum_{i=1}^N \mathbb{1}[i \in \text{top}_k(s_{i,\cdot})], \quad \text{MRR} = \frac{1}{N} \sum_{i=1}^N \frac{1}{\text{rang}(i)} \quad (10)$$

où $\text{rang}(i)$ est la position du bon sujet dans le classement des similarités décroissantes. Ces deux métriques mesurent directement la tâche opérationnelle (trouver la bonne HRTF), indépendamment de l'échelle de la perte contrastive.

10.2 Distorsion log-spectrale (LSD)

Pour comparer la HRTF récupérée à la HRTF réelle du sujet, on calcule la distorsion log-spectrale sur les coefficients SH,

$$\text{LSD} = \sqrt{(20 \log_{10} |A_{\text{pred}}| - 20 \log_{10} |A_{\text{true}}|)^2} \quad [\text{dB}], \quad (11)$$

la moyenne étant prise sur tous les coefficients SH, bins fréquentiels et canaux. Une valeur inférieure à ~ 5 dB est généralement considérée comme acoustiquement acceptable dans la littérature HRTF.

10.3 Séparabilité de l’espace latent

Le rapport entre similarité moyenne des paires correctes (S^+) et des paires incorrectes (S^-) donne une mesure globale de la structure de l’espace appris — une valeur cible $S^+/S^- > 1,5$ indique une séparation nette entre sujets plutôt qu’un espace latent effondré.

10.4 Protocole anti-fuite

Comme évoqué en section 7, l’expansion par réflexion précède le split. Le critère de succès des métriques ci-dessus est donc appliqué sur l’**identifiant de sujet de base** (`H10_mirror` $\rightarrow$ `H10`) et non sur l’identifiant exact, pour éviter de compter comme une fausse victoire une reconnaissance qui ne ferait qu’exploiter la fuite miroir train/val. Il s’agit néanmoins d’une évaluation *optimiste* : un split réalisé avant augmentation serait plus rigoureux, et constitue une amélioration identifiée pour une itération future du protocole.

11 Interprétabilité

L’architecture pose un problème non standard pour Grad-CAM [10] : la sortie est un embedding L_2 -normalisé, pas un score de classe. Le score usuel $\|z\|_2^2/d = 1/d$ est **constant** sur la sphère unité — son gradient par rapport aux cartes d’activation est identiquement nul, produisant des heatmaps vides. On lui substitue un score $\sum_j |z_j|$ (norme ℓ_1 , non constante sur $\mathbb{S}^{d-1}$), ou, pour expliquer *pourquoi* une paire (oreille, HRTF) a été mise en correspondance, le score de similarité $\text{score}(z) = \langle z, z_{\text{hrtf}}^{\text{ref}} \rangle$ avec un embedding HRTF cible fixé.

Une seconde difficulté est spécifique au backbone gelé (phases 1–2) : un appel monolithique du modèle Keras à travers une `GradientTape` ne retourne aucun gradient vers les cartes de features, la tape ne surveillant pas les variables non-entraînables et l’appel du modèle constituant une frontière opaque au graphe de gradient. La solution consiste à séparer explicitement le calcul en deux étapes : le backbone est exécuté *hors* tape (sa trainabilité devient alors indifférente, on ne demande jamais de gradient par rapport à ses poids), puis la tête est appelée *couche par couche* à l’intérieur de la tape avec `tape.watch()` explicite sur les cartes de features en sortie du backbone.

12 Discussion et limites

- **Taille du dataset.** Quelques dizaines de sujets mesurés (avant augmentation) restent peu nombreux pour un apprentissage contrastif, dont la qualité dépend directement du nombre de négatifs disponibles par batch. L’augmentation par symétrie exacte (section 7) atténue mais ne supprime pas cette contrainte.
- **Fuite partielle train/val.** Le protocole d’anti-fuite par identifiant de base (section 10) reste une mesure optimiste ; un split *avant* expansion offrirait une estimation de généralisation plus fiable, au prix d’un dataset d’entraînement plus petit.

- **Biais de la base de mesure.** Toute base HRTF mesurée sur-représente certaines morphologies selon la population recrutée ; la Gallery ne peut retrouver que des sujets présents dans sa base de référence — un nouvel utilisateur à la morphologie atypique reçoit la HRTF la plus proche disponible, pas une HRTF réellement personnalisée.
- **Qualité de l'image.** La performance du modèle dépend de conditions de prise de vue (éclairage, angle, cadrage) non contrôlées en usage réel, contrairement aux scans standardisés du dataset d'entraînement.

13 Conclusion et perspectives

Ce document formalise un modèle de personnalisation de HRTF par récupération cross-modale, où la HRTF est représentée de façon compacte et physiquement motivée par ses coefficients en harmoniques sphériques, et où l'alignement avec une paire de photos d'oreilles est appris par perte contrastive supervisée dans un espace latent L_2 -normalisé partagé. Le choix de formuler le problème comme un retrieval plutôt qu'une régression, l'augmentation par symétrie exacte plutôt que par interpolation, et le dégel progressif du backbone, répondent tous à la même contrainte structurante du projet : un nombre de sujets mesurés intrinsèquement limité.

Perspectives directes : (i) évaluation avec split réalisé avant augmentation, pour une mesure de généralisation non optimiste ; (ii) extension de l'apprentissage fédéré à un cadre multi-institutionnel réel, avec agrégation chiffrée ; (iii) fusion, à l'inférence, du sujet retrouvé par Gallery avec le moteur d'interpolation spatiale du projet, pour produire une HRTF personnalisée continue en direction plutôt que limitée aux positions mesurées du sujet retrouvé.

Références

- [1] M. Maqlach, *Représentation des HRTFs par Harmoniques Sphériques — Formalisme mathématique et justification pour l'encodage cross-modal*, document technique, docs/hrtf_spherical_harmonics.tex, 2026.
- [2] M. A. Evans, J. A. S. Angus, and A. I. Tew, *Analyzing head-related transfer function measurements using surface spherical harmonics*, J. Acoust. Soc. Am., 104(4) :2400–2411, 1998.
- [3] D. N. Zotkin, R. Duraiswami, and N. A. Gumerov, *Regularized HRTF fitting using spherical harmonics*, in Proc. IEEE WASPAA, 2009.
- [4] T. Chen, S. Kornblith, M. Norouzi, and G. Hinton, *A simple framework for contrastive learning of visual representations (SimCLR)*, ICML, 2020.
- [5] A. van den Oord, Y. Li, and O. Vinyals, *Representation learning with contrastive predictive coding*, arXiv :1807.03748, 2018.
- [6] K. Sohn, *Improved deep metric learning with multi-class N-pair loss objective*, NeurIPS, 2016.
- [7] P. Khosla, P. Teterwak, C. Wang, A. Sarna, Y. Tian, P. Isola, A. Maschinot, C. Liu, and D. Krishnan, *Supervised contrastive learning*, NeurIPS, 2020.

- [8] A. Radford, J. W. Kim, C. Hallacy, A. Ramesh, G. Goh, S. Agarwal, G. Sastry, A. Askell, P. Mishkin, J. Clark, G. Krueger, and I. Sutskever, *Learning transferable visual models from natural language supervision (CLIP)*, ICML, 2021.
- [9] M. Tan and Q. Le, *EfficientNet : Rethinking model scaling for convolutional neural networks*, ICML, 2019.
- [10] R. R. Selvaraju, M. Cogswell, A. Das, R. Vedantam, D. Parikh, and D. Batra, *Grad-CAM : Visual explanations from deep networks via gradient-based localization*, ICCV, 2017.
- [11] H. B. McMahan, E. Moore, D. Ramage, S. Hampson, and B. A. y Arcas, *Communication-efficient learning of deep networks from decentralized data*, AI-STATS, 2017.
- [12] F. Brinkmann, M. Dinakaran, R. Pelzer, P. Grosche, D. Voss, and S. Weinzierl, *A cross-evaluated database of measured and simulated HRTFs including 3D head meshes, anthropometric features, and headphone impulse responses (HUTUBS)*, J. Audio Eng. Soc., 67(9) :705–718, 2019.
- [13] UMR 9912 - STMS - IRCAM/CNRS/UPMC, *LISTEN HRTF Database*, Olivier Warusfel.